

Séries Chronologiques

Cours complet, entièrement démontré et illustré
orienté vers la résolution des exercices d'examen
d'après le cours de Fadoua BADAoui (INSEA)

Préparation au module

29 mai 2026

Esprit de ce cours

Ce cours est **recentré sur les notions effectivement évaluées** dans le recueil d'examens : tout ce qui n'est exploité par aucune question (descriptions logicielles, test de Fisher, tableau de Buys–Ballot détaillé, etc.) a été **retiré**. En revanche, chaque notion utile est **entièrement démontrée, développée et illustrée graphiquement**, avec des encadrés :

- **Recette d'examen** : la méthode pas-à-pas, reliée aux questions (Q A.x. ...).
- **Lecture graphique** : comment interpréter une figure.
- **Attention** : pièges classiques.

Notations. $(X_t)_{t \in \mathbb{Z}}$; B opérateur retard ($B^k X_t = X_{t-k}$) ; $a_t \sim \text{BB}(0, \sigma^2)$ bruit blanc ; $\gamma(k)$ autocovariance ; $\rho(k) = \gamma(k)/\gamma(0)$ autocorrélation (ACF) ; $P(k)$ autocorrélation partielle (FAP/PACF).

Table des matières

1	Décomposition d'une série chronologique	3
1.1	Série chronologique et objectif	3
1.2	Les trois composantes	3
1.3	Estimation de la tendance par moyennes mobiles	3
1.4	Coefficients saisonniers et désaisonnalisation	5
1.5	Élimination de la tendance par différenciation	5
2	Processus stationnaires au sens large	6
2.1	Définition et fonction d'autocorrélation	6
2.2	Le bruit blanc	6
2.3	Non-stationnarité : processus TS et DS, intégration	6
3	Modèles ARMA	8
3.1	Écriture polynomiale	8
3.2	Processus moyenne mobile $MA(q)$	8
3.3	Inversibilité et représentation $AR(\infty)$	8
3.4	Processus autorégressif $AR(p)$	9
3.5	Équations de Yule–Walker	10
3.6	Fonction d'autocorrélation partielle (FAP)	10
3.7	Modèle $ARMA(p, q)$ et représentations infinies	11
3.8	Le processus $ARMA(1,1)$: autocovariance	12
4	Box–Jenkins : intégration, ARIMA, validation	13
4.1	Identification par les corrélogrammes	13
4.2	Tests de racine unitaire de Dickey–Fuller	13
4.3	Processus ARIMA et SARIMA	13
4.4	Validation : test de Ljung–Box	14
5	Prévision	15
5.1	Prévision optimale et règles de calcul	15
5.2	Prévision d'un $AR(p)$ et d'un $MA(1)$	15
5.3	Erreur de prévision et intervalle de confiance	15

Chapitre 1

Décomposition d'une série chronologique

1.1. Série chronologique et objectif

Définition 1.1.1 (Série chronologique). Une *série chronologique* est une suite d'observations $X_1, \dots, X_N$ d'une grandeur, relevées à intervalle de temps fixe. On note X_t l'observation à la date t .

L'objectif central est la **prévision** de X_{T+h} ($h = 1, 2, \dots$) à partir du passé $X_1, \dots, X_T$. Pour cela, on cherche à *modéliser la dépendance temporelle* de la série, soit de façon déterministe (décomposition tendance/saisonnalité, ce chapitre), soit de façon stochastique (modèles ARMA, chapitres suivants).

1.2. Les trois composantes

Définition 1.2.1 (Composantes). On décompose une série en : la *tendance* T_t (évolution lente de long terme), la *saisonnalité* S_t (fluctuation périodique de période p : $S_{t+p} = S_t$), et le *résidu* E_t (aléa).

Définition 1.2.2 (Modèles additif / multiplicatif).

$$\text{Additif : } X_t = T_t + S_t + E_t, \quad \text{Multiplicatif : } X_t = T_t \cdot S_t \cdot E_t.$$

Additif : amplitude saisonnière *constante*. Multiplicatif : amplitude *proportionnelle au niveau*.

Lecture graphique — modèle additif ou multiplicatif ?

On trace mentalement la droite des maxima et celle des minima. Si l'écart entre les deux reste *constant* (droites parallèles) $\Rightarrow$ **additif**. Si l'écart *croît avec le niveau* (droites divergentes) $\Rightarrow$ **multiplicatif**. Sur la figure d'identification (Q I.1), comparer les panneaux (3) additif et (4) multiplicatif : dans (4) l'amplitude des oscillations augmente avec le niveau.

1.3. Estimation de la tendance par moyennes mobiles

Définition 1.3.1 (Moyenne mobile). Une *moyenne mobile* (MM) est un **filtre linéaire** $M(X)_t = \sum_{i=-m_1}^{m_2} \lambda_i X_{t-i}$. Elle est *centrée* si $m_1 = m_2$, *symétrique* si $\lambda_{-i} = \lambda_i$, *normalisée* si $\sum_i \lambda_i = 1$.

Attention — $\rightarrow$ Q A.2

Une MM est *par définition* linéaire ; elle n'est *pas* forcément centrée, symétrique ou normalisée. La bonne réponse au QCM est donc « filtre linéaire, pas forcément centré ou symétrique ».

Définition 1.3.2 (MM centrée d'ordre p). Pour absorber une saisonnalité de période p : si p *impair*, $MM_p(X)_t = \frac{1}{p} \sum_{i=-(p-1)/2}^{(p-1)/2} X_{t-i}$; si p *pair*, on centre en pondérant les bords par $\frac{1}{2}$, ex.

$$MM_4(X)_t = \frac{1}{8}X_{t-2} + \frac{1}{4}X_{t-1} + \frac{1}{4}X_t + \frac{1}{4}X_{t+1} + \frac{1}{8}X_{t+2}.$$




Figure 1.1 – Décomposition additive d'une série : $X_t = T_t + S_t + E_t$ (tendance linéaire, saisonnalité de période 12, bruit).

Théorème 1.3.1 (Propriétés d'une MM d'ordre p). *La MM centrée d'ordre p :* (i) **laisse invariante** une tendance affine $T_t = \alpha + \beta t$; (ii) **annule** une saisonnalité de période p (de somme nulle sur une période) ; (iii) **réduit** la variance du bruit.

Démonstration. (i) Pour p impair, $\frac{1}{p} \sum_{i=-m}^m (\alpha + \beta(t-i)) = \alpha + \beta t - \frac{\beta}{p} \sum_{i=-m}^m i = \alpha + \beta t$ (la somme des i symétriques est nulle). Pour p pair, le même calcul avec les poids $\frac{1}{2}$ aux bords redonne $\alpha + \beta t$. (ii) Si S_t est de période p et $\sum_{j=1}^p S_j = 0$, la moyenne sur une fenêtre couvrant exactement une période vaut $\frac{1}{p} \sum_{j=1}^p S_j = 0$. (iii) Si $E_t \sim \text{BB}(0, \sigma^2)$, $\text{Var}(\frac{1}{p} \sum E_{t-i}) = \sigma^2/p < \sigma^2$. $\square$




Figure 1.2 – La MM4 centrée appliquée à une série trimestrielle : elle gomme la saisonnalité de période 4 et restitue la tendance.

Recette d'examen — → Q A.3

La MM_p absorbe la saisonnalité de période p et conserve une tendance linéaire. En particulier la **MM4** conserve les tendances linéaires et absorbe les saisonnalités de période 4. Pour une série de période p , on extrait la tendance par MM_p .

1.4. Coefficients saisonniers et désaisonnalisation

Méthode 1.4.1 (Coefficients saisonniers et série CVS). 1. Estimer T_t (par MM_p ou par régression linéaire $\hat{T}_t = \hat{a}t + \hat{b}$).

2. *Données sans tendance* : $Y_t - T_t$ (additif) ou Y_t/T_t (multiplicatif).

3. Pour chaque saison $j = 1, \dots, p$: S_j = moyenne des données sans tendance de la saison j .

4. **Correction (conservation des aires)** : la moyenne des S_j doit valoir 0 (additif) ou 1 (multiplicatif). On pose $S'_j = S_j - \bar{S}$ (additif) ou $S'_j = S_j/\bar{S}$ (multiplicatif).

5. *Série CVS* : $CVS_t = Y_t - S'_{j(t)}$ (additif) ou $Y_t/S'_{j(t)}$ (multiplicatif).

6. *Prévision* : $\hat{X}_t = \hat{T}_t + S'_{j(t)}$ (additif) ou $\hat{T}_t S'_{j(t)}$.

Recette d'examen — Régression de la tendance ; → Q H.1, H.4

$$\hat{a} = \frac{n \sum tY - \sum t \sum Y}{n \sum t^2 - (\sum t)^2}, \hat{b} = \bar{Y} - \hat{a}\bar{t}. \text{ La prévision linéaire en } t_0 \text{ est } \hat{a}t_0 + \hat{b}.$$

1.5. Élimination de la tendance par différenciation

Définition 1.5.1. $\Delta X_t = (1 - B)X_t = X_t - X_{t-1}$; $\Delta^2 X_t = (1 - B)^2 X_t$.

Proposition 1.5.1. Si $X_t = \alpha + \beta t + e_t$ (tendance linéaire) alors $\Delta X_t = \beta + \Delta e_t$. Si $X_t = \alpha + \beta t + \delta t^2 + e_t$ alors $\Delta^2 X_t = 2\delta + \Delta^2 e_t$.

Démonstration. $\Delta(\alpha + \beta t) = \beta$; $\Delta(\delta t^2) = \delta(t^2 - (t-1)^2) = \delta(2t-1)$, puis $\Delta^2(\delta t^2) = \delta[(2t-1) - (2t-3)] = 2\delta$. $\square$

La différenciation est l'outil pour stationnariser une tendance *stochastique* (chapitre 4) ; on ne l'applique qu'après diagnostic (test de racine unité).

Remarque 1.5.1 (Sur les lissages, → Q A.7, A.8). Le *lissage exponentiel simple* ajuste localement une *constante* (ne capte ni tendance ni saison). Le lissage double (Holt) capte la tendance ; le lissage de *Holt-Winters* capte tendance et saisonnalité. L'algorithme *X11* estime la série CVS de façon itérative en combinant régressions et moyennes mobiles (→ Q A.4).

Chapitre 2

Processus stationnaires au sens large

2.1. Définition et fonction d'autocorrélation

Définition 2.1.1 (Stationnarité au sens large, SSL). (X_t) est *SSL* (ou du second ordre) si : (i) $\mathbb{E}(X_t) = m$ constante ; (ii) $\mathbb{E}(X_t^2) < \infty$; (iii) $\gamma(k) = \text{Cov}(X_t, X_{t+k})$ ne dépend que de k . On note $\gamma(0) = \text{Var}(X_t)$ et $\rho(k) = \gamma(k)/\gamma(0)$ (ACF).

Proposition 2.1.1 (Propriétés de γ et ρ). $\gamma(-k) = \gamma(k)$; $|\gamma(k)| \leq \gamma(0)$; $\rho(0) = 1$; $|\rho(k)| \leq 1$.

Démonstration. Parité : $\gamma(-k) = \text{Cov}(X_t, X_{t-k}) = \text{Cov}(X_{t-k}, X_t) = \gamma(k)$ (par stationnarité, on décale de k). L'inégalité $|\gamma(k)| \leq \gamma(0)$ découle de Cauchy-Schwarz : $|\text{Cov}(X_t, X_{t+k})| \leq \sqrt{\text{Var}(X_t)\text{Var}(X_{t+k})} = \gamma(0)$. $\square$

Définition 2.1.2 (Stationnarité stricte). (X_t) est *strictement stationnaire* si la loi de $(X_{t_1}, \dots, X_{t_n})$ est invariante par translation. Si de plus $\mathbb{E}(X_t^2) < \infty$, alors strict $\Rightarrow$ SSL.

Recette d'examen $\rightarrow$ Q A.15, A.16

SSL ne porte que sur les *deux premiers moments* (donc vérifiable) ; la stationnarité *stricte* porte sur toute la loi. Strict + carré intégrable $\Rightarrow$ SSL.

2.2. Le bruit blanc

Définition 2.2.1 (Bruit blanc). $(a_t) \sim \text{BB}(0, \sigma^2)$ si $\mathbb{E}(a_t) = 0$, $\text{Var}(a_t) = \sigma^2$, $\gamma(k) = 0$ pour $k \neq 0$. Fort si les a_t sont i.i.d. ; faible s'ils sont seulement non corrélés ; gaussien si i.i.d. $N(0, \sigma^2)$.

Exemple 2.2.1 $(X_t = a_t - a_{t-1})$. $\mathbb{E}(X_t) = 0$; $\gamma(0) = \text{Var}(a_t) + \text{Var}(a_{t-1}) = 2\sigma^2$; $\gamma(1) = \text{Cov}(a_t - a_{t-1}, a_{t-1} - a_{t-2}) = -\sigma^2$; $\gamma(k) = 0$ ($k \geq 2$). Indépendant de t : X_t est SSL.

Exemple 2.2.2 (Le processus $X_t = (-1)^t z$; $\rightarrow$ Q B.1). Soit z avec $\mathbb{E}(z) = 0$, $\text{Var}(z) = 1$. Alors $\mathbb{E}(X_t) = (-1)^t \mathbb{E}(z) = 0$ et

$$\gamma(k) = \text{Cov}((-1)^t z, (-1)^{t+k} z) = (-1)^{2t+k} \mathbb{E}(z^2) = (-1)^k,$$

indépendant de t . Donc (X_t) est **SSL**, avec $\gamma(0) = 1$ et $\rho(k) = (-1)^k$.

2.3. Non-stationnarité : processus TS et DS, intégration

Définition 2.3.1 (TS, *trend stationary*). (X_t) est TS s'il s'écrit $X_t = f(t) + Z_t$, f déterministe (ex. $f(t) = \alpha + \beta t$), Z_t stationnaire. On le rend stationnaire en *retranchant la tendance*.

Définition 2.3.2 (DS / intégration). (X_t) est *intégré d'ordre d* , $X_t \sim I(d)$, si $(1-B)^d X_t$ est stationnaire et d est minimal. Pour $d = 1$: $(1-B)X_t$ stationnaire $\iff X_t = X_{t-1} + Z_t$ (DS).

Théorème 2.3.1 (La marche aléatoire est non stationnaire). Soit $X_t = X_{t-1} + a_t$ (i.e. $(1-B)X_t = a_t$), X_0 fixé. Alors $X_t = X_0 + \sum_{j=1}^t a_j$, donc $\text{Var}(X_t) = t\sigma^2 \rightarrow \infty$: (X_t) n'est pas SSL, $X_t \sim I(1)$.

Démonstration. Par récurrence $X_t = X_0 + a_1 + \dots + a_t$; les a_j étant non corrélés, $\text{Var}(X_t) = \sum_{j=1}^t \sigma^2 = t\sigma^2$ dépend de t . $\square$




Figure 2.1 — Marche aléatoire $I(1)$ (gauche) et son ACF empirique (droite) : décroissance *très lente* caractéristique de la non-stationnarité.

Lecture graphique — reconnaître une non-stationnarité

Une série non stationnaire a une ACF empirique qui **décroît très lentement** ($\hat{\rho}(1) \approx 1$). Une série stationnaire a une ACF qui **décroît rapidement vers 0**. C'est le premier diagnostic visuel ($\rightarrow$ tests de Dickey-Fuller, ch. 4).

Attention — $\rightarrow$ Q A.14 ; Q F.4(e)

Stationnaire $\neq$ bruit blanc : un $AR(1)$ est stationnaire mais fortement autocorrélé. On ne stationnarise un *TS* qu'en retranchant la tendance, un *DS* qu'en différenciant ; *sur-différencier* une série stationnaire *augmente* la variance.

Chapitre 3

Modèles ARMA

3.1. Écriture polynomiale

Le modèle linéaire général $X_t = \mu + \sum_{i=1}^p \phi_i X_{t-i} + a_t - \sum_{j=1}^q \theta_j a_{t-j}$ s'écrit $\Phi_p(B)X_t = \mu + \Theta_q(B)a_t$, avec $\Phi_p(B) = 1 - \phi_1 B - \dots - \phi_p B^p$ et $\Theta_q(B) = 1 - \theta_1 B - \dots - \theta_q B^q$.

3.2. Processus moyenne mobile MA(q)

Définition 3.2.1. $X_t = \mu + a_t + \theta_1 a_{t-1} + \dots + \theta_q a_{t-q}$, $a_t \sim \text{BB}(0, \sigma^2)$.

Théorème 3.2.1 (Moments du MA(q)). $\mathbb{E}(X_t) = \mu$ et

$$\gamma(k) = \begin{cases} (1 + \theta_1^2 + \dots + \theta_q^2)\sigma^2, & k = 0, \\ \sigma^2(\theta_k + \sum_{j=1}^{q-k} \theta_j \theta_{k+j}), & 1 \leq k \leq q, \\ 0, & k > q, \end{cases} \quad (\theta_0 := 1).$$

Tout MA(q) est SSL.

Démonstration. Posons $Y_t = X_t - \mu = \sum_{i=0}^q \theta_i a_{t-i}$. Comme $\text{Cov}(a_{t-i}, a_{t+k-j}) = \sigma^2$ ssi $t-i = t+k-j$, i.e. $j = i+k$, on a $\gamma(k) = \text{Cov}(Y_t, Y_{t+k}) = \sum_{i,j} \theta_i \theta_j \text{Cov}(a_{t-i}, a_{t+k-j}) = \sigma^2 \sum_i \theta_i \theta_{i+k}$, la somme portant sur $0 \leq i, i+k \leq q$. Pour $k = 0$ on retrouve $\sigma^2 \sum_i \theta_i^2$; pour $k > q$ la somme est vide, $\gamma(k) = 0$. Comme $\gamma(k)$ ne dépend pas de t et $\mathbb{E}(X_t) = \mu$, X_t est SSL. $\square$

Corollaire 3.2.1 (ACF du MA(q) : coupure à q). $\rho(k) \neq 0$ pour $0 \leq k \leq q$ et $\rho(k) = 0$ pour $k > q$.

Exemple 3.2.1 (MA(1)). $X_t = \mu + a_t + \theta a_{t-1}$: $\gamma(0) = (1 + \theta^2)\sigma^2$, $\gamma(1) = \theta\sigma^2$, $\gamma(k) = 0$ ($k \geq 2$), donc $\rho(1) = \frac{\theta}{1 + \theta^2}$, $\rho(k) = 0$ ($k \geq 2$).




Figure 3.1 – MA(1), $\theta = 0.8$: l'ACF coupe après $k = 1$, la PACF décroît (dualité avec l'AR).

3.3. Inversibilité et représentation AR(∞)

Définition 3.3.1 (Inversibilité). Un MA(q) est *inversible* si les racines de $\Theta_q(B) = 0$ sont de module > 1 ; on peut alors écrire $a_t = \Theta_q(B)^{-1}X_t$ (forme AR(∞)).

Exemple 3.3.1. $X_t = (1 - \theta B)a_t$ avec $|\theta| < 1$: $(1 - \theta B)^{-1} = \sum_{i \geq 0} \theta^i B^i$ converge, d'où $a_t = \sum_{i \geq 0} \theta^i X_{t-i}$.

Attention —→ Q A.12

Tout MA est *stationnaire* mais n'admet une représentation AR que s'il est *inversible*. Contre-exemple : $X_t = a_t - a_{t-1}$ (racine $B = 1$) non inversible.

3.4. Processus autorégressif AR(p)

Définition 3.4.1. $X_t = \mu + \phi_1 X_{t-1} + \dots + \phi_p X_{t-p} + a_t$, $\phi_p \neq 0$.

Théorème 3.4.1 (Stationnarité et causalité). *L'AR(p) $\Phi_p(B)X_t = \mu + a_t$ est SSL et causal ssi toutes les racines de $\Phi_p(B) = 0$ sont de module strictement > 1 . Il admet alors la forme causale $X_t = \frac{\mu}{1 - \sum \phi_i} + \sum_{j \geq 0} \psi_j a_{t-j}$ avec $\psi_0 = 1$, $\sum_j \psi_j^2 < \infty$.*

Cas AR(1), entièrement détaillé. $(1 - \phi B)X_t = \mu + a_t$. ($\Leftarrow$) Si $|\phi| < 1$, la série $\sum_{k \geq 0} \phi^k B^k$ converge et inverse $(1 - \phi B)$, donc $X_t = \frac{\mu}{1 - \phi} + \sum_{k \geq 0} \phi^k a_{t-k}$, avec $\sum \phi^{2k} = \frac{1}{1 - \phi^2} < \infty$. ($\Rightarrow$) Si $\phi = 1$, alors $X_t = X_0 + t\mu + \sum_{j=1}^t a_j$ et $\text{Var}(X_t) = t\sigma^2 \rightarrow \infty$: non SSL. Plus généralement, la racine de $1 - \phi B$ est $B = 1/\phi$, de module > 1 ssi $|\phi| < 1$. $\square$

Théorème 3.4.2 (Démonstration pour l'AR(2)). *Soit $\Phi(B) = 1 - \phi_1 B - \phi_2 B^2 = (1 - \frac{B}{b_1})(1 - \frac{B}{b_2})$, b_1, b_2 racines. Posons $Y_t = (1 - \frac{B}{b_2})X_t$; alors $(1 - \frac{B}{b_1})Y_t = \mu + a_t$ est un AR(1) de paramètre $1/b_1$, stationnaire ssi $|b_1| > 1$. En réinjectant, X_t est stationnaire causal ssi $|b_1| > 1$ et $|b_2| > 1$, et $X_t = \frac{\mu}{1 - \phi_1 - \phi_2} + \sum_{j \geq 0} \psi_j a_{t-j}$.*

Corollaire 3.4.1 (Moments de l'AR(1) causal, $|\phi| < 1$).

$$\mathbb{E}(X_t) = \frac{\mu}{1 - \phi}, \quad \text{Var}(X_t) = \frac{\sigma^2}{1 - \phi^2}, \quad \gamma(k) = \frac{\sigma^2}{1 - \phi^2} \phi^{|k|}, \quad \rho(k) = \phi^{|k|}.$$

Démonstration. Causalité $\Rightarrow \text{Cov}(a_t, X_{t-1}) = 0$. D'où $\text{Var}(X_t) = \phi^2 \text{Var}(X_{t-1}) + \sigma^2 \Rightarrow \gamma(0) = \sigma^2/(1 - \phi^2)$. Puis $\gamma(k) = \text{Cov}(X_t, \phi X_{t+k-1} + \mu + a_{t+k}) = \phi \gamma(k-1)$ pour $k \geq 1$, donc $\gamma(k) = \phi^k \gamma(0)$ et $\rho(k) = \phi^k$. $\square$




Figure 3.2 – Trajectoires d'AR(1) : forte persistance ($\phi = 0.8$), alternance de signe ($\phi = -0.8$), quasi-bruit ($\phi = 0.3$).

Lecture graphique — reconnaître un AR(1) sur le graphe

$\phi > 0$: trajectoire lisse et persistante, ACF qui décroît en restant positive. $\phi < 0$: trajectoire en dents de scie, ACF alternée (+, -, +, ...). Plus $|\phi|$ est proche de 1, plus la mémoire (et la décroissance lente de l'ACF) est forte.




Figure 3.3 – ACF d'un AR(1) : décroissance géométrique $\rho(k) = \phi^k$ (monotone si $\phi > 0$, oscillante si $\phi < 0$).

3.5. Équations de Yule–Walker

Théorème 3.5.1 (Yule–Walker). *Pour un AR(p) SSL causal,*

$$\rho(k) = \sum_{j=1}^p \phi_j \rho(k-j) \quad (k \geq 1), \quad \gamma(0) = \frac{\sigma^2}{1 - \sum_{j=1}^p \phi_j \rho(j)}.$$

Cas AR(2) : $\rho(1) = \frac{\phi_1}{1 - \phi_2}$, $\rho(2) = \phi_1 \rho(1) + \phi_2$.

Démonstration. Pour $k \geq 1$: $\gamma(k) = \text{Cov}(X_{t-k}, \sum_j \phi_j X_{t-j} + \mu + a_t) = \sum_j \phi_j \gamma(k-j)$ car $\text{Cov}(X_{t-k}, a_t) = 0$ ($k \geq 1$, causalité). Diviser par $\gamma(0)$ donne la récurrence. Pour $k = 0$: $\gamma(0) = \sum_j \phi_j \gamma(j) + \text{Cov}(X_t, a_t) = \sum_j \phi_j \gamma(j) + \sigma^2$, d'où $\gamma(0)$. Pour l'AR(2), $k = 1$: $\rho(1) = \phi_1 + \phi_2 \rho(1)$ (car $\rho(-1) = \rho(1)$), soit $\rho(1) = \phi_1 / (1 - \phi_2)$; $k = 2$: $\rho(2) = \phi_1 \rho(1) + \phi_2$. $\square$

Recette d'examen — Estimation par Yule–Walker ; $\rightarrow$ Q G.1–G.3, J.16

On résout $\boldsymbol{\rho} = R \boldsymbol{\phi} \Rightarrow \boldsymbol{\phi} = R^{-1} \boldsymbol{\rho}$, puis $\hat{\sigma}^2 = \gamma(0)(1 - \sum \phi_j \rho(j))$. AR(1) : $\hat{\phi} = \hat{\rho}(1)$; AR(2) :
 $\hat{\phi}_1 = \frac{\rho_1(1 - \rho_2)}{1 - \rho_1^2}$, $\hat{\phi}_2 = \frac{\rho_2 - \rho_1^2}{1 - \rho_1^2}$.

3.6. Fonction d'autocorrélation partielle (FAP)

Définition 3.6.1 (FAP). $P(k)$ est la corrélation entre X_t et X_{t+k} après élimination de l'effet linéaire des variables intermédiaires. On a $P(1) = \rho(1)$ et, par la formule matricielle de Yule–Walker tronquée,

$$P(2) = \frac{\begin{vmatrix} 1 & \rho_1 \\ \rho_1 & \rho_2 \end{vmatrix}}{\begin{vmatrix} 1 & \rho_1 \\ \rho_1 & 1 \end{vmatrix}} = \frac{\rho_2 - \rho_1^2}{1 - \rho_1^2}.$$

Théorème 3.6.1 (FAP d'un AR(p) : coupure à p). *Pour un AR(p) : $P(k) = 0$ pour $k > p$, et $P(p) = \phi_p$.*

Idée. La projection de X_t sur $X_{t-1}, \dots, X_{t-k}$ a pour dernier coefficient ϕ_{kk} solution de Yule–Walker à l'ordre k . Pour $k > p$, le modèle exact n'utilise que p retards, donc $\phi_{kk} = 0$; pour $k = p$, $\phi_{pp} = \phi_p$. $\square$

Théorème 3.6.2 (Dualité AR / MA).

	ACF (ρ)	FAP (P)
AR (p)	décroît (exp. /sinus amortie)	nulle pour $k > p$
MA (q)	nulle pour $k > q$	décroît
ARMA (p, q)	décroît	décroît




Figure 3.4 – AR(2), $\phi_1 = 0.5, \phi_2 = 0.3$: l'ACF décroît, la PACF coupe après $k = 2$ ($P(2) = \phi_2$).

Recette d'examen — Identifier p et q ; $\rightarrow$ Q A.9, A.10, D.5, I.2, I.3

FAP coupe à p et ACF décroît $\Rightarrow$ AR(p). ACF coupe à q et FAP décroît $\Rightarrow$ MA(q).
Les deux décroissent $\Rightarrow$ ARMA. Bande de non-significativité $\pm 2/\sqrt{n}$.

3.7. Modèle ARMA(p, q) et représentations infinies

Définition 3.7.1. $\Phi_p(B)X_t = \mu + \Theta_q(B)a_t$: stationnaire/causal ssi racines de Φ_p de module > 1 ; inversible ssi racines de Θ_q de module > 1 . Alors $\mathbb{E}(X_t) = \mu/(1 - \phi_1 - \dots - \phi_p)$.

Théorème 3.7.1 (Coefficients ψ_k (MA ∞) et π_k (AR ∞)). — *Forme MA(∞)* $X_t = \sum_k \psi_k a_{t-k}$: $\Phi(B)\Psi(B) = \Theta(B)$, d'où $\psi_k = \theta_k^\Theta + \sum_{j=1}^k \phi_j \psi_{k-j}$ ($\psi_0 = 1$).
 — *Forme AR(∞)* $a_t = \sum_k \pi_k X_{t-k}$: $\Theta(B)\Pi(B) = \Phi(B)$, d'où $\pi_k = \phi_k^\Phi - \sum_{j=1}^k \theta_j^\Theta \pi_{k-j}$ ($\pi_0 = 1$), où θ_j^Θ (resp. ϕ_j^Φ) est le coefficient de B^j dans Θ (resp. Φ); attention aux signes : $\phi_j^\Phi = -\phi_j$, $\theta_j^\Theta = -\theta_j$.

Démonstration. Identification des coefficients de B^k dans l'égalité polynomiale $\Phi\Psi = \Theta$: $\sum_{j=0}^k \phi_j^\Phi \psi_{k-j} = \theta_k^\Theta$ avec $\phi_0^\Phi = 1$, d'où la récurrence en isolant ψ_k . Idem pour π via $\Theta\Pi = \Phi$. $\square$

Exemple 3.7.1 (AR(2) $X_t - 0.9X_{t-1} + 0.2X_{t-2} = a_t$; $\rightarrow$ Q C.1). $\psi_k = 0.9\psi_{k-1} - 0.2\psi_{k-2}$: $\psi_1 = 0.9, \psi_2 = 0.61, \psi_3 = 0.369$. Racines des inverses 0.5, 0.4, d'où $\psi_k = 5(0.5)^k - 4(0.4)^k$.

Exemple 3.7.2 $((1 - 0.8B)X_t = (1 + 0.4B)a_t$; $\rightarrow$ Q C.3, B.5). MA ∞ : $\psi_k = 0.8\psi_{k-1}, \psi_1 = 1.2 \Rightarrow \psi_k = 1.2(0.8)^{k-1}$. AR ∞ : $\pi_k = -0.4\pi_{k-1}, \pi_1 = -1.2$.

Attention — Racines communes; $\rightarrow$ Q B.3, B.4, J.3

Si Φ et Θ partagent une racine, **simplifier d'abord**. Ex. $(1 - 1.66B + 0.66B^2) = (1 - B)(1 - 0.66B)$ et le second membre $(1 - B)a_t$: le facteur $(1 - B)$ se simplifie, laissant l'AR(1) fini $(1 - 0.66B)X_t = a_t$.

3.8. Le processus ARMA(1,1) : autocovariance

Théorème 3.8.1 (Autocovariances de l'ARMA(1,1)). *Pour $X_t = \phi X_{t-1} + a_t + \theta a_{t-1}$ (stationnaire, $|\phi| < 1$) :*

$$\gamma(0) = \sigma^2 \frac{1 + 2\phi\theta + \theta^2}{1 - \phi^2}, \quad \gamma(1) = \sigma^2 \frac{(1 + \phi\theta)(\phi + \theta)}{1 - \phi^2}, \quad \gamma(k) = \phi \gamma(k-1) \quad (k \geq 2).$$

Démonstration. On a $\text{Cov}(X_t, a_t) = \sigma^2$ et $\text{Cov}(X_t, a_{t-1}) = (\phi + \theta)\sigma^2$ (en multipliant l'équation par a_t, a_{t-1} et en prenant l'espérance, via la causalité). Puis : $\gamma(0) = \mathbb{E}[X_t(\phi X_{t-1} + a_t + \theta a_{t-1})] = \phi\gamma(1) + \sigma^2 + \theta(\phi + \theta)\sigma^2$ et $\gamma(1) = \mathbb{E}[X_t(\phi X_t + \dots)]$...on résout le système linéaire en $\gamma(0), \gamma(1)$, ce qui donne les formules. Pour $k \geq 2$, l'équation ne fait plus intervenir de terme MA courant : $\gamma(k) = \phi\gamma(k-1)$. $\square$

Proposition 3.8.1 (Somme de processus indépendants ; $\rightarrow$ Q D.6, J.18, J.19). *La somme de deux ARMA indépendants $ARMA(p_1, q_1)$ et $ARMA(p_2, q_2)$ est un $ARMA(p_1 + p_2, \max(p_1 + q_2, p_2 + q_1))$. En particulier : **AR(1) + bruit blanc = ARMA(1,1)** et **AR(1) + MA(1) = ARMA(1,1)** (après réduction).*

Chapitre 4

Box–Jenkins : intégration, ARIMA, validation

4.1. Identification par les corrélogrammes

La démarche de Box–Jenkins : (1) *stationnariser* (différenciation si l'ACF décroît lentement) ; (2) *identifier* p, q via ACF/PACF (théorème 3.6.2) ; (3) *estimer* ; (4) *valider* (résidus = bruit blanc).

4.2. Tests de racine unitaire de Dickey–Fuller

Définition 4.2.1 (DF simple). On teste la présence d'une racine unité dans un AR(1) via l'un des modèles :

$$(1) \Delta X_t = \rho X_{t-1} + \alpha + \beta t + a_t, \quad (2) \Delta X_t = \rho X_{t-1} + \alpha + a_t, \quad (3) \Delta X_t = \rho X_{t-1} + a_t,$$

où $\rho = \phi - 1$. $H_0 : \rho = 0$ (i.e. $\phi = 1$, racine unité, non stationnaire) contre $H_1 : \phi < 1$ (AR(1) stationnaire). Statistique $t_\phi = \frac{\hat{\phi} - 1}{\hat{\sigma}_{\hat{\phi}}}$, comparée aux valeurs critiques de la table de Dickey–Fuller (et non de Student).

Méthode 4.2.1 (Stratégie et décision). On part du modèle (1) ; si β n'est pas significatif on passe à (2), puis à (3). **Décision** : si t_ϕ est *supérieur* (moins négatif) à la valeur critique, on *ne rejette pas* $H_0 \Rightarrow$ racine unité $\Rightarrow$ différencier.

Exemple 4.2.1 ($\rightarrow$ Q F.4). $\hat{\phi} = 0.996$, $\hat{\sigma}_{\hat{\phi}} = 0.0061$, $t_\phi = -0.645 > -2.89$: on ne rejette pas H_0 , donc $X_t \sim I(1)$. Après différenciation, $\hat{\rho}(1) \approx 0$: ΔX_t est un bruit blanc $\Rightarrow$ marche aléatoire, modèle ARIMA(0, 1, 0).

Le test *ADF* (augmenté) étend ceci aux AR(p) en ajoutant des termes $\sum_j \phi_j \Delta X_{t-j}$.

4.3. Processus ARIMA et SARIMA

Définition 4.3.1 (ARIMA(p, d, q)). Si $X_t \sim I(d)$ et $(1 - B)^d X_t$ est un ARMA(p, q) stationnaire : $\Phi_p(B)(1 - B)^d X_t = \Theta_q(B)a_t$. Cas : ARIMA($p, 0, q$) = ARMA(p, q) ; ARIMA(0, 1, 0) = marche aléatoire.

Recette d'examen — Trouver (p, d, q) ; $\rightarrow$ Q F.1, F.2, F.3, J.13

1. Tester $\Phi(1) = 0$ (c.-à-d. $\sum \phi_i = 1$) et factoriser $(1 - B)$ autant que possible $\rightarrow d$. **2.** Le polynôme stationnaire restant donne p ; le polynôme MA donne q .

Exemple 4.3.1 ($\rightarrow$ Q F.1). $1 - 2.65B + 2.3B^2 - 0.65B^3 = (1 - B)^2(1 - 0.65B)$ (deux racines unités) $\Rightarrow X_t \sim I(2)$, ARIMA(1, 2, 0).

Définition 4.3.2 (SARIMA). $\Phi_p(B)\Phi_P(B^s)(1 - B)^d(1 - B^s)^D X_t = \Theta_q(B)\Theta_Q(B^s)a_t$: il modélise *tendance et/ou saisonnalité* (période s). $\rightarrow$ Q A.11, I.3.

4.4. Validation : test de Ljung–Box

Définition 4.4.1 (Statistique de Ljung–Box). Après ajustement d'un ARMA(p, q), on teste la *blancheur des résidus* :

$$LB = n(n+2) \sum_{k=1}^K \frac{\hat{\rho}_k^2}{n-k} \xrightarrow{H_0} \chi_{K-p-q}^2,$$

H_0 : « résidus = bruit blanc ». On **rejette** H_0 si $LB > \chi_{K-p-q, 1-\alpha}^2$.

Exemple 4.4.1 ($\rightarrow$ Q J.21). ARMA(1,1), $K = 14$: ddl = $14 - 1 - 1 = 12$, $\chi_{12,0.95}^2 = 21.03$. Si $LB = 18.386 < 21.03$, on *ne rejette pas* H_0 : résidus compatibles avec un bruit blanc, modèle validé.

Recette d'examen — Validation complète ; $\rightarrow$ Q A.13, A.19–A.21

(i) significativité des paramètres (Student) ; (ii) **blancheur des résidus** (Ljung–Box, ACF/PACF des résidus) ; (iii) normalité (Jarque–Bera). *Sélection* : **AIC** = $-2 \ln L + 2k$, **BIC** = $-2 \ln L + k \ln n$ (on *minimise*).

Chapitre 5

Prévision

5.1. Prévision optimale et règles de calcul

Définition 5.1.1. La meilleure prévision (au sens de l'erreur quadratique moyenne) de X_{n+h} connaissant le passé est $\hat{X}_{n+h} = \mathbb{E}[X_{n+h} | \mathcal{F}_n]$.

Méthode 5.1.1 (Calcul). Écrire l'équation à la date $n+h$; remplacer les chocs *futurs* a_{n+j} ($j \geq 1$) par 0, les chocs *passés* par les résidus, et les X futurs par leurs prévisions.

5.2. Prévision d'un AR(p) et d'un MA(1)

Théorème 5.2.1 (AR(p)). $\hat{X}_{n+h} = \mu + \sum_{j=1}^p \phi_j \hat{X}_{n+h-j}$ (avec $\hat{X}_{n+i} = X_{n+i}$ pour $i \leq 0$). En particulier AR(1) : $\hat{X}_{n+h} = \phi^h X_n + \mu \sum_{j=0}^{h-1} \phi^j \xrightarrow{h \rightarrow \infty} \frac{\mu}{1-\phi}$.

Théorème 5.2.2 (MA(1)). $\hat{X}_{n+1} = \mu + \theta a_n$, et $\hat{X}_{n+h} = \mu$ pour $h \geq 2$ (au-delà de l'horizon q , un MA(q) prévoit sa moyenne).

5.3. Erreur de prévision et intervalle de confiance

Théorème 5.3.1 (Erreur de prévision). Via la forme MA(∞) $X_t = \mu + \sum_j \psi_j a_{t-j}$,

$$\Delta_h = X_{n+h} - \hat{X}_{n+h} = \sum_{j=0}^{h-1} \psi_j a_{n+h-j}, \quad \text{Var}(\Delta_h) = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2.$$

Cas AR(1). En itérant $X_{n+h} = \mu \sum_{j=0}^{h-1} \phi^j + \phi^h X_n + \sum_{j=0}^{h-1} \phi^j a_{n+h-j}$. Or $\hat{X}_{n+h} = \mu \sum_{j=0}^{h-1} \phi^j + \phi^h X_n$ (chocs futurs nuls), d'où $\Delta_h = \sum_{j=0}^{h-1} \phi^j a_{n+h-j}$ et $\text{Var}(\Delta_h) = \sigma^2 \sum_{j=0}^{h-1} \phi^{2j}$. $\square$

Corollaire 5.3.1. AR(1) : $\text{Var}(\Delta_h) = \sigma^2(1 + \phi^2 + \dots + \phi^{2(h-1)})$. MA(1) : $\text{Var}(\Delta_1) = \sigma^2$, $\text{Var}(\Delta_h) = (1 + \theta^2)\sigma^2$ ($h \geq 2$).

Théorème 5.3.2 (Intervalle de confiance). Sous $a_t \sim N(0, \sigma^2)$ i.i.d., $\Delta_h \sim N(0, \sigma^2 \sum_{j=0}^{h-1} \psi_j^2)$ et

$$\boxed{\hat{X}_{n+h} \pm z_{1-\alpha/2} \sigma \sqrt{\sum_{j=0}^{h-1} \psi_j^2}} \quad (z_{0.975} = 1.96).$$

Lecture graphique — la bande de confiance

L'incertitude $\sqrt{\sum_{j < h} \psi_j^2}$ croît avec h : on prévoit d'autant moins précisément que l'horizon est lointain. Pour un AR(1) stationnaire la variance d'erreur tend vers $\gamma(0) = \sigma^2/(1 - \phi^2)$; pour un MA(1) elle est constante dès $h \geq 2$.

Recette d'examen — Prévision + IC, méthode ; $\rightarrow$ Q E.1–E.7, J.2

1. Calculer $\hat{X}_{n+h}$ (chocs futurs = 0). 2. Coefficients ψ_j . 3. $\text{Var}(\Delta_h) = \sigma^2 \sum_{j < h} \psi_j^2$. 4. IC $= \hat{X}_{n+h} \pm 1.96 \sigma \sqrt{\sum_{j < h} \psi_j^2}$.




Figure 5.1 – Prédiction d'un AR(1) : la prédiction converge vers la moyenne et la bande de confiance s'**élargit** avec l'horizon (puis se stabilise).

Exemple 5.3.1 ($\rightarrow$ Q.E.1). MA(1) $X_t = 2 + a_t + 0.8a_{t-1}$, $\sigma^2 = 2$, $a_t = 1.6$: $\hat{X}_{t+1} = 2 + 0.8(1.6) = 3.28$, IC = $3.28 \pm 1.96\sqrt{2}$; $\hat{X}_{t+2} = 2$, IC = $2 \pm 1.96\sqrt{(1 + 0.64)2} = 2 \pm 1.96\sqrt{3.28}$.