

Séries Chronologiques

Cours complet, structuré et rigoureux
orienté vers la résolution des exercices d'examen
d'après le cours de Fadoua BADAoui (INSEA)

Préparation au module

29 mai 2026

Comment utiliser ce cours

Ce document **réorganise et détaille** le cours de Séries Chronologiques. Chaque notion est accompagnée de **définitions rigoureuses**, de **théorèmes démontrés** lorsqu'utile, et d'encadrés **Recette d'examen** reliant la théorie aux questions du recueil (références $\rightarrow$ Q A.x, Q B.x, ... de *Questions_SC.pdf*).

Notations. $(X_t)_{t \in \mathbb{Z}}$ série/processus ; B opérateur retard ($B^k X_t = X_{t-k}$) ; a_t (ou ε_t) bruit blanc $BB(0, \sigma^2)$; $\gamma(k)$ autocovariance, $\rho(k)$ autocorrélation, $P(k)$ autocorrélation partielle (FAP).

Table des matières

1	Introduction et décomposition des séries chronologiques	3
1.1	Qu'est-ce qu'une série chronologique ?	3
1.2	Les trois composantes d'une série	3
1.3	Estimation de la tendance par moyennes mobiles	3
1.4	Calcul des coefficients saisonniers et désaisonnalisation	4
1.5	Élimination de la tendance par différenciation	4
2	Processus stationnaires au sens large	5
2.1	Définition et fonction d'autocorrélation	5
2.2	Le bruit blanc	5
2.3	Non-stationnarité : processus TS et DS	5
3	Modèles ARMA	7
3.1	Opérateur retard et écriture polynomiale	7
3.2	Processus moyenne mobile $MA(q)$	7
3.3	Inversibilité d'un MA et représentation $AR(\infty)$	7
3.4	Processus autorégressif $AR(p)$	7
3.5	Équations de Yule-Walker	8
3.6	Fonction d'autocorrélation partielle (FAP)	8
3.7	Modèle $ARMA(p,q)$ et représentations infinies	9
4	Box-Jenkins : intégration, ARIMA, SARIMA, validation	10
4.1	Détection de la non-stationnarité	10
4.2	Tests de Dickey-Fuller	10
4.3	Processus ARIMA et SARIMA	10
4.4	Détection de la saisonnalité	11
4.5	Validation d'un modèle : test de Ljung-Box	11
5	Prévision	12
5.1	Prévision optimale	12
5.2	Prévision d'un $AR(p)$	12
5.3	Prévision d'un $MA(1)$	12
5.4	Erreur de prévision et intervalle de confiance	12
5.5	Évaluation des prévisions	13

Chapitre 1

Introduction et décomposition des séries chronologiques

1.1. Qu'est-ce qu'une série chronologique ?

Définition 1.1.1 (Série chronologique). Une *série chronologique* (ou série temporelle) est une suite d'observations $X_{t_1}, X_{t_2}, \dots, X_{t_N}$ d'une grandeur, ordonnées dans le temps et généralement relevées à intervalle fixe h . On la note $X_1, \dots, X_N$ et on étudie les couples (t, X_t) .

L'objectif de l'analyse est de *caractériser la dépendance temporelle* de la série, afin de la comprendre, de la décrire et surtout d'en **prévoir** les valeurs futures X_{T+h} , $h = 1, 2, \dots$ à partir du passé $X_1, \dots, X_T$.

On distingue trois approches historiques : la représentation graphique, les méthodes *déterministes* (décomposition tendance/saisonnalité), et les méthodes *stochastiques* (modèles ARMA), qui font l'objet des chapitres suivants.

1.2. Les trois composantes d'une série

Définition 1.2.1 (Composantes). On décompose usuellement une série en trois composantes :

- la *tendance* T_t : évolution moyenne à long terme ;
- la *composante saisonnière* S_t : fluctuation périodique de période p ($S_{t+p} = S_t$), liée au calendrier ;
- la *composante résiduelle* E_t : ce qui n'est expliqué ni par T ni par S (aléa).

Définition 1.2.2 (Modèles additif et multiplicatif).

$$\text{Additif : } X_t = T_t + S_t + E_t, \quad \text{Multiplicatif : } X_t = T_t \cdot S_t \cdot E_t.$$

Dans le modèle additif, l'amplitude des oscillations saisonnières est *constante* ; dans le modèle multiplicatif, elle *croît avec le niveau* de la série.

Méthode 1.2.1 (Choix additif / multiplicatif). On trace les droites passant par les maxima et par les minima : si elles sont *parallèles*, le modèle est additif ; sinon, multiplicatif. Le *test de Buys-Ballot* le confirme : on régresse l'écart-type annuel σ_i sur la moyenne annuelle $\bar{x}_i$ ($\sigma_i = a_1 \bar{x}_i + a_0 + \epsilon_i$) ; si a_1 n'est pas significativement $\neq 0$ (test de Student), le schéma est additif, sinon multiplicatif.

1.3. Estimation de la tendance par moyennes mobiles

Définition 1.3.1 (Moyenne mobile). Une *moyenne mobile* est un **filtre linéaire**

$$M(X)_t = \sum_{i=-m_1}^{m_2} \lambda_i X_{t-i}.$$

Elle est *centrée* si $m_1 = m_2$, *symétrique* si $\lambda_{-i} = \lambda_i$, *normalisée* si $\sum_i \lambda_i = 1$.

Attention

Une moyenne mobile est *par définition* un filtre linéaire ; elle n'est *pas* nécessairement centrée, ni symétrique, ni normalisée (ce sont des propriétés *supplémentaires*). → **Q A.2.**

Définition 1.3.2 (MM centrée d'ordre p). Pour une série de période saisonnière p :

- si p est *impair* : $MM_p(X)_t = \frac{1}{p} \sum_{i=-(p-1)/2}^{(p-1)/2} X_{t-i}$;
- si p est *pair* (ex. $p = 4$ ou 12) : on *centre* en pondérant les extrémités par $\frac{1}{2}$:

$$MM_4(X)_t = \frac{1}{8}X_{t-2} + \frac{1}{4}X_{t-1} + \frac{1}{4}X_t + \frac{1}{4}X_{t+1} + \frac{1}{8}X_{t+2}.$$

Théorème 1.3.1 (Propriétés fondamentales d'une MM d'ordre p). La *moyenne mobile centrée* d'ordre p :

- (i) laisse invariante (*conserve*) une *tendance* affine $T_t = a + bt$;
- (ii) absorbe (*annule*) une *composante saisonnière* de période p ;
- (iii) atténue la *variance du bruit* (*lissage*).

Idée. (i) Pour $T_t = a + bt$, la moyenne symétrique des p valeurs voisines vaut $a + bt$ (les écarts $\pm i$ se compensent). (ii) Pour S_t de période p avec $\sum_j S_j = 0$, la somme sur une fenêtre complète d'une période est nulle. (iii) La moyenne de p variables réduit la variance d'un facteur $\sim 1/p$. $\square$

Recette d'examen — Questions sur la MM4

La **MM4** *conserve* les tendances linéaires et *absorbe* les saisonnalités de période 4. $\rightarrow$ **Q A.3**.
Plus généralement, pour extraire la tendance d'une série de période p , on lisse par MM_p .

1.4. Calcul des coefficients saisonniers et désaisonnalisation

Méthode 1.4.1 (Coefficients saisonniers (modèle additif)). 1. Estimer la tendance T_t (par MM d'ordre p ou par régression).

2. Calculer les *données sans tendance* $Y_t - T_t$ (additif) ou Y_t/T_t (multiplicatif).
3. Pour chaque saison $j = 1, \dots, p$, faire la *moyenne* des données sans tendance : $S_j = \frac{1}{n} \sum_i (Y_{ij} - T_{ij})$ (additif).
4. *Corriger* (principe de conservation des aires) : la moyenne des S_j doit être *nulle* (additif) ou *égale à 1* (multiplicatif). On pose $S'_j = S_j - \bar{S}$ (additif) ou $S'_j = S_j/\bar{S}$ (multiplicatif).

Définition 1.4.1 (Série corrigée des variations saisonnières (CVS)). $CVS_t = Y_t - S'_{j(t)}$ (additif) ou $Y_t/S'_{j(t)}$ (multiplicatif). La prévision combine extrapolation de la tendance et coefficient saisonnier : $\hat{X}_t = \hat{T}_t + S'_{j(t)}$ (additif) ou $\hat{T}_t \cdot S'_{j(t)}$ (multiplicatif).

Recette d'examen — Exercices de décomposition

Schéma type ($\rightarrow$ **Q H.1–H.4**) : (1) tracer ; (2) tendance (MCO $\hat{a}, \hat{b}$ ou MM_p) ; (3) coefficients saisonniers (moyenne des écarts/rapports, puis recentrage) ; (4) prévisions $\hat{T}_t + S'_j$; (5) CVS.

Régression MCO : $\hat{a} = \frac{n \sum tY - \sum t \sum Y}{n \sum t^2 - (\sum t)^2}$, $\hat{b} = \bar{Y} - \hat{a}\bar{t}$.

1.5. Élimination de la tendance par différenciation

Définition 1.5.1 (Opérateur de différence). $\Delta X_t = (1-B)X_t = X_t - X_{t-1}$, et $\Delta^2 X_t = (1-B)^2 X_t$.

Proposition 1.5.1. Si $T_t = a + bt$ (*tendance linéaire*), alors $\Delta X_t = b + \Delta e_t$ (*élimine la tendance et laisse une constante*). Si $T_t = a + bt + ct^2$, alors $\Delta^2 X_t = 2c + \Delta^2 e_t$.

La différenciation est l'outil pour stationnariser une série à *tendance stochastique* (cf. chapitre 2) ; on n'y recourt qu'après diagnostic (test de racine unité).

Chapitre 2

Processus stationnaires au sens large

2.1. Définition et fonction d'autocorrélation

Définition 2.1.1 (Stationnarité au sens large (SSL)). Un processus (X_t) est *stationnaire au sens large* (ou du second ordre) si :

- (i) $\mathbb{E}(X_t) = m$ constante (indépendante de t);
- (ii) $\mathbb{E}(X_t^2) < \infty$;
- (iii) la fonction d'autocovariance $\gamma(k) = \text{Cov}(X_t, X_{t+k}) = \mathbb{E}[(X_t - m)(X_{t+k} - m)]$ ne dépend que de k (pas de t).

On a $\gamma(0) = \text{Var}(X_t)$ et la *fonction d'autocorrélation* (ACF) $\rho(k) = \frac{\gamma(k)}{\gamma(0)}$.

Propriété 2.1.1. γ est paire ($\gamma(-k) = \gamma(k)$), $|\gamma(k)| \leq \gamma(0)$, $\rho(0) = 1$, $|\rho(k)| \leq 1$, et γ est de type positif.

Définition 2.1.2 (Stationnarité stricte). (X_t) est *strictement stationnaire* si la loi de $(X_{t_1}, \dots, X_{t_n})$ est invariante par translation temporelle. Si de plus $\mathbb{E}(X_t^2) < \infty$, alors strict $\Rightarrow$ SSL. $\rightarrow$ **Q A.15–A.16.**

2.2. Le bruit blanc

Définition 2.2.1 (Bruit blanc). $(a_t) \sim \text{BB}(0, \sigma^2)$ si $\mathbb{E}(a_t) = 0$, $\text{Var}(a_t) = \sigma^2$ et $\gamma(k) = 0$ pour $k \neq 0$. C'est le processus SSL « sans mémoire ».

— *Bruit blanc fort* : les a_t sont i.i.d.; *faible* : seulement non corrélés. *Gaussien* : $a_t \sim \text{i.i.d. } N(0, \sigma^2)$.

Exemple 2.2.1. $X_t = a_t - a_{t-1}$: $\mathbb{E}(X_t) = 0$, $\gamma(0) = 2\sigma^2$, $\gamma(1) = -\sigma^2$, $\gamma(k) = 0$ ($k \geq 2$) : indépendant de t , donc SSL.

Exemple 2.2.2 ($X_t = (-1)^t z$; $\rightarrow$ **Q B.1**). Si $\mathbb{E}(z) = 0$, $\text{Var}(z) = 1$: $\mathbb{E}(X_t) = 0$ et $\gamma(k) = (-1)^t(-1)^{t+k}\mathbb{E}(z^2) = (-1)^k$, indépendant de t . Le processus est donc *SSL* (même s'il n'est pas ergodique).

2.3. Non-stationnarité : processus TS et DS

Définition 2.3.1 (Processus TS (*trend stationary*)). (X_t) est TS s'il s'écrit $X_t = f(t) + Z_t$ avec f déterministe (ex. $f(t) = a + bt$) et Z_t stationnaire. On le stationnarise en *retirant la tendance* : $X_t - f(t) = Z_t$. *Non-stationnarité déterministe* (le moment d'ordre 1 dépend de t).

Définition 2.3.2 (Processus DS (*difference stationary*), intégration). (X_t) est DS (intégré d'ordre 1, $X_t \sim I(1)$) si $(1 - B)X_t$ est stationnaire. Plus généralement $X_t \sim I(d)$ si $(1 - B)^d X_t$ est stationnaire et d est le plus petit tel entier. *Non-stationnarité stochastique* (les moments d'ordre 2 dépendent de t).

Exemple 2.3.1 (Marche aléatoire). $X_t = X_{t-1} + a_t$, soit $(1 - B)X_t = a_t$: $X_t = X_0 + \sum_{j=1}^t a_j$, $\text{Var}(X_t) = t\sigma^2$ croît avec t : non stationnaire, $I(1)$.

Attention — Distinguer TS et DS

On stationnarise un *TS* en retirant la tendance ($X_t - \hat{f}(t)$), un *DS* en *différenciant*. Différencier un TS (ou sur-différencier) introduit une racine MA unité et *augmente* la variance. → **Q F.4(e)**.

Rappel de cours — Stationnaire $\neq$ bruit blanc

Un processus stationnaire peut être fortement autocorrélé (AR(1)). Le test de Ljung-Box (« autocorrélations nulles ») n'est donc pas accepté pour une série stationnaire quelconque ; il s'applique aux *résidus* d'un modèle. → **Q A.14**.

Chapitre 3

Modèles ARMA

3.1. Opérateur retard et écriture polynomiale

Le modèle linéaire général s'écrit

$$X_t = \mu + \phi_1 X_{t-1} + \cdots + \phi_p X_{t-p} + a_t - \theta_1 a_{t-1} - \cdots - \theta_q a_{t-q},$$

soit $\Phi_p(B)X_t = \mu + \Theta_q(B)a_t$ avec $\Phi_p(B) = 1 - \phi_1 B - \cdots - \phi_p B^p$ et $\Theta_q(B) = 1 - \theta_1 B - \cdots - \theta_q B^q$.

3.2. Processus moyenne mobile MA(q)

Définition 3.2.1 (MA(q)). $X_t = \mu + a_t + \theta_1 a_{t-1} + \cdots + \theta_q a_{t-q}$, $a_t \sim \text{BB}(0, \sigma^2)$.

Théorème 3.2.1 (Moments du MA(q)). $\mathbb{E}(X_t) = \mu$, et

$$\gamma(k) = \begin{cases} (1 + \theta_1^2 + \cdots + \theta_q^2)\sigma^2 & k = 0, \\ \sigma^2(\theta_k + \sum_{j=1}^{q-k} \theta_j \theta_{k+j}) & 1 \leq k \leq q, \\ 0 & k > q. \end{cases}$$

Tout MA(q) est SSL (somme finie de bruits blancs).

Corollaire 3.2.1 (ACF du MA(q)). $\rho(k) \neq 0$ pour $0 \leq k \leq q$ et $\rho(k) = 0$ pour $k > q$: **l'ACF d'un MA(q) coupe à l'ordre q**. C'est l'outil d'identification de l'ordre q.

Exemple 3.2.1 (MA(1)). $X_t = \mu + a_t + \theta a_{t-1}$: $\gamma(0) = (1 + \theta^2)\sigma^2$, $\gamma(1) = \theta\sigma^2$, $\rho(1) = \frac{\theta}{1 + \theta^2}$, $\rho(k) = 0$ ($k \geq 2$). → **Q J.9**.

3.3. Inversibilité d'un MA et représentation AR(∞)

Définition 3.3.1 (Inversibilité). Un MA(q) est *inversible* si les racines de $\Theta_q(B) = 0$ sont de module > 1 . On peut alors écrire $a_t = \Theta_q(B)^{-1}X_t$, soit un AR(∞).

Exemple 3.3.1 (MA(1) inversible). $X_t = a_t - \theta a_{t-1} = (1 - \theta B)a_t$: si $|\theta| < 1$, $a_t = (1 - \theta B)^{-1}X_t = \sum_{i \geq 0} \theta^i X_{t-i}$ (AR(∞)).

Attention — → Q A.12

Tout MA est *stationnaire*, mais n'admet une représentation AR que s'il est *inversible*.
Contre-exemple : $X_t = a_t - a_{t-1}$ (racine $B = 1$) n'est pas inversible.

3.4. Processus autorégressif AR(p)

Définition 3.4.1 (AR(p)). $X_t = \mu + \phi_1 X_{t-1} + \cdots + \phi_p X_{t-p} + a_t$, $\phi_p \neq 0$, $a_t \sim \text{BB}(0, \sigma^2)$.

Théorème 3.4.1 (Stationnarité et causalité de l'AR(p)). L'AR(p) $\Phi_p(B)X_t = \mu + a_t$ est SSL et causal si et seulement si toutes les racines de $\Phi_p(B) = 0$ sont de module **strictement supérieur à 1**. Il admet alors la représentation causale (MA(∞))

$$X_t = \frac{\mu}{1 - \phi_1 - \cdots - \phi_p} + \sum_{j \geq 0} \psi_j a_{t-j}, \quad \psi_0 = 1, \quad \sum_j \psi_j^2 < \infty.$$

Cas AR(1). Pour $X_t = \mu + \phi X_{t-1} + a_t$, on écrit $(1 - \phi B)X_t = \mu + a_t$. Si $|\phi| < 1$, $(1 - \phi B)^{-1} = \sum_{k \geq 0} \phi^k B^k$ converge et

$$X_t = \frac{\mu}{1 - \phi} + \sum_{k \geq 0} \phi^k a_{t-k}.$$

Réciproquement, si $\phi = 1$: $X_t = t\mu + X_0 + \sum_{j=1}^t a_j$, $\text{Var}(X_t) = t\sigma^2 \rightarrow \infty$, donc non SSL. La racine de $1 - \phi B$ est $B = 1/\phi$, de module > 1 ssi $|\phi| < 1$. $\square$

Corollaire 3.4.1 (Moments de l'AR(1) causal, $|\phi| < 1$).

$$\mathbb{E}(X_t) = \frac{\mu}{1 - \phi}, \quad \text{Var}(X_t) = \frac{\sigma^2}{1 - \phi^2}, \quad \gamma(k) = \frac{\sigma^2}{1 - \phi^2} \phi^{|k|}, \quad \rho(k) = \phi^{|k|}.$$

Démonstration. $\text{Var}(X_t) = \phi^2 \text{Var}(X_{t-1}) + \sigma^2$ (car $\text{Cov}(a_t, X_{t-1}) = 0$ par causalité), d'où $\text{Var} = \sigma^2/(1 - \phi^2)$. Puis $\gamma(k) = \text{Cov}(X_t, \phi X_{t+k-1} + \mu + a_{t+k}) = \phi \gamma(k-1)$ pour $k \geq 1$, donc $\gamma(k) = \phi^k \gamma(0)$. $\square$

Recette d'examen — Tester la stationnarité d'un AR

Écrire $\Phi(B)$, calculer ses racines, vérifier $|B_i| > 1$. Pour un AR(2) $1 - \phi_1 B - \phi_2 B^2$, conditions équivalentes : $\phi_1 + \phi_2 < 1$, $\phi_2 - \phi_1 < 1$, $|\phi_2| < 1$. **Astuce racine unité** : si $\Phi(1) = 0$ (c.-à-d. $\sum \phi_i = 1$), il y a une racine $B = 1 \Rightarrow$ non stationnaire / intégré. $\rightarrow$ **Q B.2, B.4, F.1–F.3.**

3.5. Équations de Yule–Walker

Théorème 3.5.1 (Yule–Walker). Pour un AR(p) SSL causal,

$$\rho(k) = \sum_{j=1}^p \phi_j \rho(k-j) \quad (k \geq 1), \quad \gamma(0) = \frac{\sigma^2}{1 - \sum_{j=1}^p \phi_j \rho(j)}.$$

En particulier, pour l'AR(2) : $\rho(1) = \frac{\phi_1}{1 - \phi_2}$, $\rho(2) = \phi_1 \rho(1) + \phi_2$.

Démonstration. $\gamma(k) = \text{Cov}(X_t, X_{t+k}) = \text{Cov}(X_t, \sum_j \phi_j X_{t+k-j} + \mu + a_{t+k}) = \sum_j \phi_j \gamma(k-j)$ pour $k \geq 1$ (car $\text{Cov}(X_t, a_{t+k}) = 0$). On divise par $\gamma(0)$. Pour $k = 0$: $\gamma(0) = \sum_j \phi_j \gamma(j) + \sigma^2$. $\square$

Recette d'examen — Estimation par Yule–Walker

On inverse le système $\boldsymbol{\rho} = R\boldsymbol{\phi}$: $\boldsymbol{\phi} = R^{-1}\boldsymbol{\rho}$, où $R = [\rho(|i-j|)]$. Pour l'AR(1) : $\hat{\phi} = \hat{\rho}(1)$. Pour l'AR(2) : $\hat{\phi}_1 = \frac{\rho_1(1 - \rho_2)}{1 - \rho_1^2}$, $\hat{\phi}_2 = \frac{\rho_2 - \rho_1^2}{1 - \rho_1^2}$. $\rightarrow$ **Q G.1–G.3, J.16.**

3.6. Fonction d'autocorrélation partielle (FAP)

Définition 3.6.1 (FAP). L'autocorrélation partielle $P(k)$ d'ordre k est la corrélation entre X_t et X_{t+k} une fois retiré l'effet linéaire des variables intermédiaires $X_{t+1}, \dots, X_{t+k-1}$. On a $P(1) = \rho(1)$ et

$$P(2) = \frac{\rho(2) - \rho(1)^2}{1 - \rho(1)^2}.$$

Théorème 3.6.1 (FAP d'un AR(p)). Pour un AR(p) : $P(k) = 0$ pour tout $k > p$, et $P(p) = \phi_p$. La FAP d'un AR(p) coupe à l'ordre p .

Théorème 3.6.2 (Dualité AR / MA).

	<i>ACF</i> (simple)	<i>FAP</i> (partielle)
$AR(p)$	décroît (exp. / sinus amortie)	nulle pour $k > p$
$MA(q)$	nulle pour $k > q$	décroît
$ARMA(p,q)$	décroît	décroît

Recette d'examen — Identifier p et q

ACF coupe à q et FAP décroît $\Rightarrow MA(q)$. FAP coupe à p et ACF décroît $\Rightarrow AR(p)$. Les deux décroissent $\Rightarrow ARMA$. Bande de significativité $\approx \pm 2/\sqrt{n}$. $\rightarrow$ **Q A.9–A.10, D.5, I.2–I.3.**

3.7. Modèle ARMA(p,q) et représentations infinies

Définition 3.7.1 (ARMA(p,q)). $\Phi_p(B)X_t = \mu + \Theta_q(B)a_t$. Il est *stationnaire/causal* ssi les racines de Φ_p sont de module > 1 , *inversible* ssi les racines de Θ_q le sont. Alors $\mathbb{E}(X_t) = \frac{\mu}{1 - \phi_1 - \dots - \phi_p}$.

Méthode 3.7.1 (Calcul des coefficients ψ_k (MA_∞) et π_k (AR_∞)). — **MA(∞)** $X_t = \Psi(B)a_t$: identifier $\Phi(B)\Psi(B) = \Theta(B)$, d'où la récurrence $\psi_k = \theta_k^\Theta + \sum_{j=1}^k \phi_j \psi_{k-j}$ ($\psi_0 = 1$), où θ_k^Θ est le coefficient de B^k dans Θ .

— **AR(∞)** $\Pi(B)X_t = a_t$: identifier $\Theta(B)\Pi(B) = \Phi(B)$, d'où $\pi_k = \phi_k^\Phi - \sum_{j=1}^k \theta_j^\Theta \pi_{k-j}$ ($\pi_0 = 1$, attention aux signes : $\Phi = 1 - \phi_1 B - \dots$ donne $\phi_1^\Phi = -\phi_1$, etc.).

Exemple 3.7.1 ($\rightarrow$ **Q C.1**). $AR(2)$ $X_t - 0.9X_{t-1} + 0.2X_{t-2} = a_t$: $\psi_k = 0.9\psi_{k-1} - 0.2\psi_{k-2}$, $\psi_0 = 1$: $\psi_1 = 0.9$, $\psi_2 = 0.61$, $\psi_3 = 0.369$, et $\psi_k = 5(0.5)^k - 4(0.4)^k$ (racines 0.5, 0.4 des inverses).

Exemple 3.7.2 ($\rightarrow$ **Q C.3**). $(1 - 0.8B)X_t = (1 + 0.4B)a_t$: $MA(\infty)$ $\psi_k = 0.8\psi_{k-1}$ ($\psi_1 = 1.2$), soit $\psi_k = 1.2(0.8)^{k-1}$; $AR(\infty)$ $\pi_k = -0.4\pi_{k-1}$ ($\pi_1 = -1.2$).

Attention — Racines communes

Si Φ et Θ ont une *racine commune*, on simplifie avant de conclure ! Ex. $(1 - 1.66B + 0.66B^2)X_t = (1 - B)a_t = (1 - B)(1 - 0.66B)X_t = (1 - B)a_t$ se réduit à $(1 - 0.66B)X_t = a_t$ (AR(1) fini). $\rightarrow$ **Q B.3, J.3.**

Proposition 3.7.1 (Somme de processus indépendants). *La somme d'un ARMA(p_1, q_1) et d'un ARMA(p_2, q_2) indépendants est un ARMA($p_1 + p_2, \max(p_1 + q_2, p_2 + q_1)$). En particulier $AR(1) + MA(1) = ARMA(1, 1)$ après réduction (et $AR(1) + \text{bruit blanc} = ARMA(1, 1)$). $\rightarrow$ **Q D.6, J.18–J.19.***

Chapitre 4

Box–Jenkins : intégration, ARIMA, SARIMA, validation

4.1. Détection de la non-stationnarité

Méthodes : examen visuel ; comparaison moyenne/variance sur sous-échantillons ; décroissance de l'ACF (lente $\approx 1 \Rightarrow$ non stationnaire) ; *tests de racine unité*.

4.2. Tests de Dickey–Fuller

Définition 4.2.1 (Test DF simple). On teste la présence d'une racine unité dans un AR(1). Trois modèles :

$$(1) X_t - \phi X_{t-1} = \alpha + \beta t + a_t, \quad (2) X_t - \phi X_{t-1} = \alpha + a_t, \quad (3) X_t - \phi X_{t-1} = a_t.$$

$H_0 : \phi = 1$ (racine unité, non stationnaire) contre $H_1 : \phi < 1$ (AR(1) stationnaire). Statistique $t_\phi = \frac{\hat{\phi} - 1}{\hat{\sigma}_{\hat{\phi}}}$, comparée aux valeurs critiques de la table de Dickey–Fuller (*non* celles de Student).

Méthode 4.2.1 (Stratégie séquentielle). Étudier (1) : si β non significatif, passer à (2) ; si α non significatif, passer à (3). **Règle de décision** : si t_ϕ est *supérieur* (moins négatif) que la valeur critique, on *ne rejette pas* $H_0 \Rightarrow$ racine unité, série non stationnaire $\Rightarrow$ différencier.

Exemple 4.2.1 ($\rightarrow$ **Q F.4**). $\hat{\phi} = 0.996$, $\hat{\sigma}_{\hat{\phi}} = 0.0061$, $t_\phi = -0.645 > -2.89$: on ne rejette pas $H_0 \Rightarrow I(1)$. Après différenciation, $\hat{\rho}(1) \approx 0 \Rightarrow$ marche aléatoire, modèle ARIMA(0, 1, 0).

Le test DF augmenté (ADF) étend ceci aux AR(p) en ajoutant des termes $\sum_j \phi_j \Delta X_{t-j}$.

4.3. Processus ARIMA et SARIMA

Définition 4.3.1 (ARIMA(p, d, q)). Si $X_t \sim I(d)$ et $Y_t = (1 - B)^d X_t$ est un ARMA(p, q) stationnaire, alors X_t est un ARIMA(p, d, q) :

$$\Phi_p(B) (1 - B)^d X_t = \Theta_q(B) a_t.$$

Cas particuliers : ARIMA($p, 0, q$) = ARMA(p, q) ; ARIMA(0, 1, 0) = marche aléatoire.

Recette d'examen — Déterminer ARIMA(p, d, q)

1. Tester $\Phi(1) = 0$ et factoriser $(1 - B)$ autant de fois que possible $\rightarrow$ ordre d . **2.** Le polynôme stationnaire restant donne p ; le polynôme MA donne q . Ex. ($\rightarrow$ **Q F.1**) : $1 - 2.65B + 2.3B^2 - 0.65B^3 = (1 - B)^2(1 - 0.65B) \Rightarrow I(2)$, ARIMA(1, 2, 0).

Définition 4.3.2 (SARIMA). $\Phi_p(B)\Phi_P(B^s)(1 - B)^d(1 - B^s)^D X_t = \Theta_q(B)\Theta_Q(B^s)a_t$: combine parties régulière et saisonnière (période s). Il modélise *tendance et/ou saisonnalité*. $\rightarrow$ **Q A.11, I.3**.

4.4. Détection de la saisonnalité

Outils : représentation graphique et tableau de *Buys–Ballot* ; *test de Fisher* (ANOVA : effet « période » significatif $\Rightarrow$ saisonnalité ; effet « année » $\Rightarrow$ tendance) ; *ACF* (pics aux multiples de la période s).

4.5. Validation d'un modèle : test de Ljung–Box

Définition 4.5.1 (Statistique de Ljung–Box). Après ajustement d'un $\text{ARMA}(p, q)$, on teste la blancheur des *résidus* :

$$\text{LB} = n(n+2) \sum_{k=1}^K \frac{\hat{\rho}_k^2}{n-k} \xrightarrow{H_0} \chi_{K-p-q}^2.$$

H_0 : « résidus = bruit blanc ». On rejette H_0 si $\text{LB} > \chi_{K-p-q, 1-\alpha}^2$.

Exemple 4.5.1 ($\rightarrow$ **Q J.21**). $\text{ARMA}(1,1)$, $K = 14$, $\text{LB} = 18.386$: ddl = $14 - 1 - 1 = 12$, seuil $\chi_{12,0.95}^2 = 21.03$. Comme $18.386 < 21.03$, on *ne rejette pas* H_0 : résidus compatibles avec un bruit blanc, modèle validé.

Recette d'examen — Validation complète

(i) significativité des paramètres (Student) ; (ii) **blancheur des résidus** (Ljung–Box, ACF/-PACF des résidus) ; (iii) normalité (Jarque–Bera, pour les IC). Sélection entre modèles candidats : **AIC** = $-2 \ln L + 2k$, **BIC** = $-2 \ln L + k \ln n$ (minimiser). $\rightarrow$ **Q A.13, A.19–A.21**.

Chapitre 5

Prévision

5.1. Prévision optimale

Définition 5.1.1 (Prévision optimale). La meilleure prévision (au sens de l'erreur quadratique moyenne) de X_{n+h} connaissant $X_1, \dots, X_n$ est l'espérance conditionnelle $\hat{X}_{n+h} = \mathbb{E}[X_{n+h} | \mathcal{F}_n]$.

Méthode 5.1.1 (Règles de calcul). Dans l'équation du modèle écrite à la date $n+h$: remplacer les chocs *futurs* a_{n+j} ($j \geq 1$) par 0, les chocs *passés* par les résidus estimés, et les X futurs par leurs prévisions déjà calculées.

5.2. Prévision d'un AR(p)

Théorème 5.2.1. Pour $X_t = \mu + \sum_{j=1}^p \phi_j X_{t-j} + a_t$: $\hat{X}_{n+1} = \mu + \sum_{j=1}^p \phi_j X_{n+1-j}$, et plus généralement $\hat{X}_{n+h} = \mu + \sum_{j=1}^p \phi_j \hat{X}_{n+h-j}$ (avec $\hat{X}_{n+i} = X_{n+i}$ pour $i \leq 0$).

Corollaire 5.2.1 (AR(1)). $\hat{X}_{n+h} = \phi^h X_n + \mu \sum_{j=0}^{h-1} \phi^j$. Quand $h \rightarrow \infty$, $\hat{X}_{n+h} \rightarrow \frac{\mu}{1-\phi} = \mathbb{E}(X)$.
→ **QE.2, E.6, E.7, G.3, J.2, J.17.**

5.3. Prévision d'un MA(1)

Théorème 5.3.1. Pour $X_t = \mu + a_t + \theta a_{t-1}$: $\hat{X}_{n+1} = \mu + \theta a_n$ et $\hat{X}_{n+h} = \mu$ pour $h \geq 2$. (Au-delà de l'horizon q , un MA(q) prévoit la moyenne.) → **QE.1, E.3, E.4.**

5.4. Erreur de prévision et intervalle de confiance

Théorème 5.4.1 (Erreur de prévision). Via la forme MA(∞) $X_t = \mu + \sum_j \psi_j a_{t-j}$, l'erreur à horizon h est

$$\Delta_h = X_{n+h} - \hat{X}_{n+h} = \sum_{j=0}^{h-1} \psi_j a_{n+h-j}, \quad \text{Var}(\Delta_h) = \sigma^2 \sum_{j=0}^{h-1} \psi_j^2.$$

Corollaire 5.4.1 (Cas usuels). — AR(1) : $\text{Var}(\Delta_h) = \sigma^2(1 + \phi^2 + \dots + \phi^{2(h-1)})$.

— MA(1) : $\text{Var}(\Delta_1) = \sigma^2$, $\text{Var}(\Delta_h) = (1 + \theta^2)\sigma^2$ pour $h \geq 2$.

Théorème 5.4.2 (Intervalle de confiance). Sous $a_t \sim N(0, \sigma^2)$ i.i.d., $\Delta_h \sim N(0, \sigma^2 \sum_{j=0}^{h-1} \psi_j^2)$ et une IC à $1 - \alpha$ pour X_{n+h} est

$$\hat{X}_{n+h} \pm z_{1-\alpha/2} \sigma \sqrt{\sum_{j=0}^{h-1} \psi_j^2} \quad (z_{0.975} = 1.96).$$

Recette d'examen — Prévision + IC, méthode d'examen

1. Identifier le modèle et sa forme. 2. Calculer $\hat{X}_{n+h}$ (remplacer futurs $a = 0$). 3. Calculer les ψ_j et $\text{Var}(\Delta_h)$. 4. IC = $\hat{X}_{n+h} \pm 1.96 \sigma \sqrt{\sum \psi_j^2}$. → **QE.1–E.7, J.2.**

Exemple 5.4.1 (→ **QE.1**). MA(1) $X_t = 2 + a_t + 0.8a_{t-1}$, $\sigma^2 = 2$, $a_t = 1.6$: $\hat{X}_{t+1} = 2 + 0.8(1.6) = 3.28$, IC = $3.28 \pm 1.96\sqrt{2}$; $\hat{X}_{t+2} = 2$, IC = $2 \pm 1.96\sqrt{(1+0.64) \cdot 2} = 2 \pm 1.96\sqrt{3.28}$.

5.5. Évaluation des prévisions

Critères hors échantillon : $\text{RMSE} = \sqrt{\frac{1}{h} \sum_{i=1}^h (X_{n+i} - \hat{X}_{n+i})^2}$, MAE, MAPE. Le choix d'une méthode dépend du contexte, de la qualité/quantité des données, du degré d'urgence et des ressources disponibles.